

Bureau / Bureau Balance 1차 EDA 결과 보고서

작성일: 2026-07-28

비전공자용 설명 보강: 2026-07-29

분석 노트북: 07.27 1차 EDA.ipynb

분석 범위: 외부 금융기관 신용계약(**bureau**)과 계약별 월간 상태 이력(**bureau_balance**)

목차

Bureau / Bureau Balance 1차 EDA 결과 보고서

- 0. 금융을 처음 접하는 독자를 위한 사전 안내
 - 0.1 이 문서는 무엇을 확인하는가
 - 0.2 한 명의 고객이 데이터에서 보이는 방식
 - 0.3 꼭 알아야 할 용어
 - 0.4 표에 나오는 비율을 읽는 방법
 - 0.5 먼저 기억할 세 가지
- 1. 한눈에 보는 결론
- 2. 분석 배경과 데이터 의미
- 3. 데이터 규모와 올바른 결합 순서
 - 3.1 데이터 규모
 - 3.2 키와 중복 점검
 - 3.3 두 테이블의 연결 상태
- 4. 데이터 품질 점검 결과
 - 4.1 주요 결측값
 - 4.2 월별 상태 코드
 - 4.3 계약 상태와 상품 구성
 - 4.4 극단값과 영과다 변수
 - 4.5 값 범위와 시간 연속성
 - 4.6 계약 내부의 논리 불일치
- 5. 계약·고객 단위 파생변수
 - 5.1 계약 단위 월별 이력
 - 5.2 고객 단위 외부 신용 특성
 - 5.3 월별 이력과 고객 특성의 결합
 - 5.4 파생변수 검증
- 6. 기초 분포와 시각화
 - 6.1 계약 수와 관측기간
 - 6.2 계약 상태와 상품 구성
 - 6.3 총신용과 총부채
 - 6.4 월별 이력과 최근 연체
- 7. TARGET 분석 모집단과 train/test 사용 경계
 - 7.1 데이터별 역할
 - 7.2 application_train의 외부신용 이력 구성
- 8. 외부 신용이력과 상환곤란의 관계 — application_train만 사용
 - 8.1 고객당 계약 수
 - 8.2 활성 계약 비율
 - 8.3 총부채/총신용 비율
 - 8.4 과거 최대 연체 상태

8.5 연체의 최근성

- 9. 후속 분석에서 사용할 변수
- 10. 해석할 때 반드시 지켜야 할 한계
- 11. 최종 결론
- 부록 A. application_test 참고 점검의 범위
- 부록 B. 재현 및 근거 파일

0. 금융을 처음 접하는 독자를 위한 사전 안내

0.1 이 문서는 무엇을 확인하는가

고객이 우리 회사에 새 대출을 신청했다고 가정하자. 심사자는 신청서에 적힌 소득과 신청금액만 보는 것이 아니라, 그 고객이 다른 금융기관에서 이미 얼마나 많은 신용계약을 이용하고 있는지, 아직 갚아야 할 부채가 얼마나 남아 있는지, 최근에 연체한 적이 있는지도 함께 확인한다.

이 문서는 바로 그 외부 신용이력을 분석한다. 확인하려는 질문은 세 가지다.

- 1. 고객의 외부 신용계약은 데이터에 어떤 구조로 기록되어 있는가?
- 2. 현재 부채 부담과 과거 연체 이력을 고객별로 어떻게 요약해야 하는가?
- 3. 그렇게 만든 지표가 실제 상환곤란 여부와 어떤 **관측 관계**를 보이는가?

여기서 중요한 점은, 이 문서가 고객의 대출 승인-거절을 결정하는 최종 심사표가 아니라는 것이다. 1차 EDA는 “후속 분석에서 어떤 정보를 반드시 구분해서 봐야 하는가”를 정하는 단계다.

분석 단계와 데이터 사용 범위는 다음처럼 분리한다.

분석 단계	사용하는 데이터	TARGET 사용 여부
외부 계약·월별 이력의 구조와 품질 점검	bureau , bureau_balance	사용하지 않음
계약·고객 단위 파생변수 생성	bureau , bureau_balance	사용하지 않음
외부 신용특성과 상환곤란의 관계 분석	application_train + 고객 단위 파생변수	사용함
test 고객의 키-이력 커버리지 참고 점검	application_test	TARGET 이 없으므로 사용 불가

따라서 이 문서의 핵심인 **TARGET=0/1 비교**는 **application_train** 고객만을 대상으로 한다. **application_test** 는 TARGET 결과 산출에 들어가지 않으며, 참고용 데이터 연결 점검은 부록에서만 설명한다.

0.2 한 명의 고객이 데이터에서 보이는 방식

아래는 변수의 뜻을 설명하기 위한 가상 예시이며, 실제 고객 사례나 분석 결과값이 아니다.

구분	고객 A	고객 B
외부 신용계약 수	4건	4건
현재 활성 계약 수	1건	3건
활성 계약 비율	25%	75%
계약에 기록된 총신용	2,000	2,000
현재 총부채	500	1,800
총부채/총신용 비율	25%	90%
최근 12개월 연체	없음	있음

두 고객은 계약 수가 똑같이 4건이다. 그러나 고객 B는 아직 진행 중인 계약의 비중과 남은 부채 비중이 높고 최근 연체도 있다. 이 예시는 **계약 수 하나만으로는 현재 부담과 상환행동을 설명할 수 없다**는 점을 보여준다. 그래서 이번 분석에서는 계약 수, 활성 계약 비율, 부채 비율, 연체 심도와 최근성을 따로 만들었다.

금액 예시의 단위는 이해를 돕기 위한 임의 단위다. 원천 데이터의 금액을 원화로 단정하지 않는다.

0.3 꼭 알아야 할 용어

용어	쉬운 뜻	이 문서에서 주의할 점
신청 고객(Application 고객)	Home Credit에 대출을 신청한 사람	한 고객은 <code>SK_ID_CURR</code> 로 구분한다.
외부 신용계약	고객이 다른 금융기관에서 이용한 대출·신용카드 등의 계약	한 고객이 여러 계약을 가질 수 있다.
활성 계약(Active)	분석 기준시점에 아직 진행 중인 계약	활성 계약이 많다는 사실만으로 연체라고 보지는 않는다.
종료 계약(Closed)	이미 종료된 계약	과거 상환행동을 보여줄 수 있으므로 삭제하지 않는다.
총신용	외부 계약에 기록된 신용금액을 고객별로 합한 값	정확한 상품별 경제적 의미가 다를 수 있어 "소득"이나 "한도"와 같다고 보면 안 된다.
총부채	외부 계약에 기록된 현재 부채를 고객별로 합한 값	음수·결측 등 기록상 특이값이 있어 품질 플래그와 함께 본다.
연체	갚기로 한 날짜를 넘겨 상환이 늦어진 상태	<code>STATUS 1~5</code> 는 숫자가 커질수록 더 심한 연체 구간을 뜻한다.
최근성	연체가 얼마나 최근에 발생했는가	오래전 연체와 최근 12개월 연체를 구분한다.
<code>TARGET=1</code>	대출 실행 후 상환곤란이 발생한 고객	대출이 거절된 고객이라는 뜻이 아니다.
상환곤란률	집단 안에서 <code>TARGET=1</code> 인 고객의 비율	관측 비율이지 개인의 확정 부실확률이 아니다.
%p(퍼센트포인트)	두 비율을 단순히 뺀 차이	5%와 10%의 차이는 5%p다.
이력 없음	외부 계약 또는 월별 상태가 관측되지 않음	"연체 없음"이나 값 0과 같은 뜻이 아니다.

0.4 표에 나오는 비율을 읽는 방법

`application_train` 전체 고객의 상환곤란률은 **8.07%**다. 이는 비슷한 고객 100명 중 약 8명에서 상환곤란이 관측됐다는 뜻이다.

예를 들어 최근 12개월 연체 집단의 상환곤란률 11.79%는 다음처럼 읽는다.

- 전체 평균 8.07%보다 **3.72%p 높다**.
- 관측기간 연체가 없던 집단 7.20%보다 **4.59%p 높다**.
- 고객 100명으로 단순 환산하면 약 12명 대 약 7명의 차이다.

그러나 이를 "최근 연체 때문에 정확히 4.59%p 위험이 증가했다"라고 말할 수는 없다. 소득, 나이, 신청금액, 다른 부채 등 두 집단의 구성 차이를 아직 동시에 통제하지 않았기 때문이다.

0.5 먼저 기억할 세 가지

1. **현재 부담**은 활성 계약 비율과 총부채/총신용 비율로 본다.
2. **상환행동**은 과거 최대 연체 단계와 최근 12개월 연체 여부로 본다.

3. **정보의 양**은 계약 및 월별 이력 보유 여부로 본다. 정보가 없다는 사실도 하나의 특성이다.

1. 한눈에 보는 결론

이번 EDA의 목적은 Kaggle 대회 제출용 예측모델을 만드는 것이 아니다. 고객의 외부 신용이력을 이해하고, 이후 **대출 조건 조정이 가능한 고객을 설명하기 위한 기초 변수**를 만드는 것이 목적이다.

아래 결과를 읽을 때 기준점은 `application_train` 전체 고객의 상환곤란률 **8.07%**다. 각 집단의 비율이 이 기준보다 얼마나 높거나 낮은지 함께 보면 의미를 이해하기 쉽다.

핵심 결과는 다음과 같다.

1. **활성 계약 비율이 높을수록 상환곤란률이 높았다.**

활성 계약 비율이 0 초과~25%인 고객의 상환곤란률은 5.33%였지만, 75%를 초과한 고객은 11.42%였다. 두 집단의 차이는 6.09%p다. 이미 끝난 계약보다 아직 상환 중인 계약이 많은 고객일수록 현재 부담이 클 가능성을 보여준다.

2. **총부채/총신용 비율이 높을수록 상환곤란률이 뚜렷하게 높아졌다.**

비율이 0인 고객은 5.56%, 0.75 초과~1.00인 고객은 13.11%, 1을 초과한 고객은 18.61%였다. 단순히 신용계약을 보유했는지가 아니라, 기록된 신용금액 중 현재 부채가 어느 정도 남아 있는지가 중요하다는 뜻이다.

3. **최근 연체 여부가 중요했다.**

최근 12개월 연체 고객의 상환곤란률은 11.79%로, 과거에만 연체한 고객 8.17%, 관측기간 동안 연체가 없던 고객 7.20%보다 높았다. 연체 경험의 유무뿐 아니라 **언제 발생했는지**를 따로 봐야 한다.

4. **계약 수가 많다고 상환곤란률이 계속 높아지는 것은 아니었다.**

3~7건 구간은 약 7.3%였지만 15건 이상에서는 9.35%로 다시 높아졌다. 계약 수가 적다고 무조건 안전하거나 많다고 무조건 위험한 것이 아니다. 계약 수는 구간 또는 비선형 관계로 다뤄야 한다.

5. **이력이 없는 고객을 정상 고객으로 처리하면 안 된다.**

`application_train` 고객의 14.31%는 외부신용 계약이 없고, 55.69%는 계약은 있지만 월별 상태 이력이 없다. 이력 없음은 “연체하지 않았다”가 아니라 “판단할 정보가 없다”에 가깝다.

한 문장으로 요약하면, **외부 신용이력은 계약 개수만 세는 것이 아니라 현재 남은 부담, 최근 상환행동, 정보의 존재 여부를 함께 봐야 한다.**

이 결과를 바탕으로 후속 분석에서 우선 사용할 변수는 다음과 같다.

- 활성 계약 비율
- 총부채/총신용 비율
- 최근 12개월 연체 여부와 횟수
- 전체 관측기간의 최대 연체 상태
- 외부 신용계약 수
- 월별 이력 보유 여부와 커버리지

2. 분석 배경과 데이터 의미

프로젝트의 최종 목표는 단순히 고객을 승인·거절로 나누는 것이 아니다. 부실위험이 높은 고객에게 대출금액이나 상환조건을 어느 정도 조정하면 위험이 낮아지는지 설명하는 **대출 심사 보조 방법론**을 만드는 것이다.

이번 1차 EDA에서는 그중 외부 신용이력을 담당하는 두 테이블을 분석했다.

데이터	의미	분석 단위	이번 보고서에서의 역할
bureau	고객이 다른 금융기관에서 이용한 과거·현재 신용계약	계약 1건	외부 계약 특성 생성
bureau_balance	각 외부 신용계약의 월별 상태 변화	계약별 월 1건	연체 심도·최근성 특성 생성
application_train	TARGET 이 있는 신청 고객	고객 1명	TARGET=0/1 EDA의 분석 모집단
application_test	TARGET 이 없는 신청 고객	고객 1명	TARGET EDA에는 사용하지 않음; 부록의 키-커버리지 참고 점검만 수행

쉽게 말하면 **application** 은 “이번에 대출을 신청한 사람 명단”, **bureau** 는 “그 사람이 외부 금융기관에서 맺은 계약 목록”, **bureau_balance** 는 “각 계약의 월별 상태 기록”이다.

한 명의 고객에게 외부 계약이 5건 있고 각 계약의 월별 기록이 24개월씩 있다면, 데이터에는 고객 1명이 **bureau** 에서 최대 5행, **bureau_balance** 에서 최대 120행으로 나타날 수 있다. 최종 분석에서는 이 여러 행을 고객 1행으로 안전하게 요약해야 한다.

TARGET=1 은 대출 실행 후 상환곤란이 발생한 고객을 뜻한다. **승인 거절 고객을 뜻하지 않는다.**

따라서 이번 결과는 “어떤 특성을 가진 고객에게 상환곤란이 더 자주 관측됐는가”를 보여줄 뿐, 실제 승인정책이나 인과관계를 증명하지 않는다.

이후 문서에서 “라벨 고객” 또는 “TARGET 분석 고객”은 모두 **application_train** 의 307,511명을 뜻한다.

또한 이 데이터는 과거에 관측된 고객과 계약의 기록이다. 미래의 모든 고객에게 같은 비율이 그대로 적용된다고 보장하지 않는다.

3. 데이터 규모와 올바른 결합 순서

3.1 데이터 규모

테이블	행 수	열 수	메모리 사용량
bureau	1,716,428	17	약 271.48MB
bureau_balance	27,299,925	3	약 650.88MB

bureau_balance 는 약 2,730만 행이므로 원본을 반복해서 계산하면 처리 비용이 매우 크다. 따라서 다음 순서로 한 번씩 집계한 뒤 결과를 재사용했다.

```

bureau_balance 월별 행
    ↓
SK_ID_BUREAU 기준 계약 단위 집계
    ↓
bureau 계약 정보와 결합
    ↓
SK_ID_CURR 기준 고객 단위 집계
    ↓
Application 고객표와 결합

```

월별 행을 Application에 바로 연결하면 고객마다 행 수가 크게 늘어나고, 월별 이력이 긴 고객이 분석에서 과도하게 반영된다. 이번 분석은 계약 단위와 고객 단위를 차례로 거쳐 이 문제를 방지했다.

예를 들어 고객 A의 월별 기록이 60행이고 고객 B의 기록이 6행이라면, 원본 월별 행을 그대로 사용했을 때 고객 A가 고객 B보다 10배 많이 등장한다. 이는 고객 A가 10배 더 중요해서가 아니라 관측기간이 길기 때문이다. 먼저 계약 단위, 그다음 고객 단위로 집계하면 두 고객을 각각 1명으로 비교할 수 있다.

따라서 이 집계 순서는 단순한 데이터 정리 절차가 아니라 **고객별 위험을 공정한 단위로 비교하기 위한 전제조건**이다.

3.2 키와 중복 점검

- `bureau.SK_ID_BUREAU` 1,716,428개는 모두 유일했다.
- `bureau_balance` 의 `SK_ID_BUREAU + MONTHS_BALANCE` 27,299,925개 조합도 모두 유일했다.
- 결측 키, 완전 중복 행, 같은 키 안의 값 충돌은 모두 0건이었다.

한 고객에게 계약이 여러 건 있거나 한 계약에 월별 행이 여러 개 있는 것은 중복 오류가 아니라 데이터의 정상적인 1:N 구조다.

여기서 “키가 유일하다”는 것은 같은 계약 또는 같은 계약-월이 실수로 두 번 저장되지 않았다는 뜻이다. 고객이 여러 행에 나타난다는 사실 자체는 오류가 아니다.

3.3 두 테이블의 연결 상태

구분	계약 수	비율
<code>bureau_balance</code> 계약 전체	817,395	100.00%
<code>bureau</code> 와 연결되는 계약	774,354	94.73%
<code>bureau_balance</code> 에만 있는 계약	43,041	5.27%
<code>bureau</code> 계약 중 월별 이력이 있는 계약	774,354	45.11%
<code>bureau</code> 계약 중 월별 이력이 없는 계약	942,074	54.89%

`bureau_balance` 에만 있는 43,041개 계약은 고객 ID를 알 수 없어 고객 단위 특성에는 사용할 수 없다. 다만 원본 오류라고 단정하지 않고 품질 지표로 수량을 남겼다.

월별 이력이 없는 942,074개 계약도 삭제하지 않았다. 이 계약은 연체가 0인 계약이 아니라 **월별 상태를 관측할 수 없는 계약**이므로 `HAS_BUREAU_BALANCE=False` 로 구분했다.

이 구분이 중요한 이유는 다음과 같다.

- 연체 없음: 월별 상태를 실제로 봤고 연체 코드가 없었다.
- 상태 미상: 월별 행은 있지만 **X** 로 기록됐다.
- 월별 이력 없음: 판단할 월별 행 자체가 없다.

세 경우를 모두 0으로 채우면 “문제가 없었다”와 “알 수 없다”가 같은 고객으로 처리된다.

4. 데이터 품질 점검 결과

데이터 품질 점검은 분석 전의 부수 작업이 아니다. 금융 데이터에서 결측, 음수, 극단값은 실제 고객 행동일 수도 있고 기록 방식의 결과일 수도 있다. 원인을 확인하지 않은 채 삭제하거나 평균으로 채우면 위험 신호와 정보 부재가 동시에 사라질 수 있다.

4.1 주요 결측값

변수	결측 수	결측률	해석
AMT_ANNUIITY	1,226,791	71.47%	계약별 연상환액 정보 부족
AMT_CREDIT_MAX_OVERDUE	1,124,488	65.51%	최대 연체금액 정보 부족
DAYS_ENDDATE_FACT	633,653	36.92%	실제 계약 종료일
AMT_CREDIT_SUM_LIMIT	591,780	34.48%	신용한도 정보 부족
AMT_CREDIT_SUM_DEBT	257,669	15.01%	현재 부채 정보 부족
DAYS_CREDIT_ENDDATE	105,553	6.15%	예정 종료일 정보 부족
AMT_CREDIT_SUM	13	약 0.001%	전체 신용액 일부 누락

결측은 무작위로 발생하지 않았다.

- 실제 종료일 **DAYS_ENDDATE_FACT**의 결측률은 종료 계약에서 0.012%, 활성 계약에서 99.69%였다. 활성 계약에는 실제 종료일이 없는 것이 자연스럽게기 때문이다.
- **AMT_CREDIT_SUM_DEBT**가 결측인 계약의 99.96%는 **AMT_CREDIT_SUM_LIMIT**도 결측이었다.
- **AMT_CREDIT_SUM_LIMIT** 결측 계약의 85.35%는 **AMT_CREDIT_MAX_OVERDUE**도 결측이었다.
- **AMT_CREDIT_MAX_OVERDUE** 결측 계약의 66.91%는 **AMT_ANNUIITY**도 결측이었다.

따라서 단순 평균이나 중앙값으로 모두 채우지 않고, 원래 결측과 **IS_MISSING_*** 플래그를 함께 유지하는 것이 적절하다.

예를 들어 활성 계약의 실제 종료일이 비어 있는 것은 아직 계약이 끝나지 않았기 때문일 수 있다. 이 값을 전체 계약의 평균 종료일로 채우면, 존재하지 않는 종료일을 인위적으로 만들어내게 된다. 반면 부채금액 결측은 단순한 “해당 없음”인지 “정보 미수집”인지 불분명하다. 그래서 값 자체와 결측 여부를 함께 보존한다.

4.2 월별 상태 코드

월별 상태 **STATUS**는 예상한 **0 ~ 5**, **C**, **X**만 존재했고 잘못된 코드는 없었다.

상태	의미	전체 월별 행에서의 비율
0	연체 없음	27.47%
1 ~ 5	연체 단계	합계 1.26%
C	계약 종료	49.99%
X	상태 미상	21.28%

C와 X가 전체의 71.27%를 차지한다. 이를 정상 상태 0과 합치면 실제 정상·연체 비율이 왜곡되므로 별도 상태로 유지했다.

숫자 상태는 다음처럼 이해하면 된다.

- 0: 해당 월에 연체로 기록되지 않음
- 1 ~ 5: 숫자가 커질수록 더 심한 연체 구간
- C: 계약이 종료된 상태
- X: 그 달의 상태를 알 수 없음

C는 “정상 상환 완료”와 완전히 같은 뜻으로 사용하지 않았다. 계약이 종료됐다는 사실과 월별 연체가 없었다는 사실은 서로 다른 정보이기 때문이다.

4.3 계약 상태와 상품 구성

- 계약 상태는 Closed 62.88%, Active 36.74%가 대부분이었다.
- Sold는 6,527건, Bad debt는 21건으로 매우 적었다.
- 상품은 Consumer credit 72.92%, Credit card 23.43%로 두 유형이 전체의 96.35%였다.
- 통화는 currency 1이 99.92%로 대부분이었다.

희소한 상품이나 상태를 오류로 보지는 않았다. 다만 표본이 매우 작은 범주의 높은 비율은 전체 패턴처럼 과대해석하지 않아야 한다.

예를 들어 Bad debt가 매우 위험한 상태처럼 보이더라도 계약이 21건뿐이면 몇 건의 변화만으로 비율이 크게 움직인다. 따라서 희소 범주는 존재 여부를 보존하되, 단독으로 정책 기준을 만들지 않는다.

4.4 극단값과 영과다 변수

일부 금액과 횟수 변수는 대부분 0이면서 소수의 큰 값이 존재했다.

변수	0의 비율	양수 집단의 특징
CREDIT_DAY_OVERDUE	99.75%	양수 4,217건, 중앙값 34일, 최대 2,792일
AMT_CREDIT_SUM_OVERDUE	99.76%	양수 4,158건, 중앙값 283.5, 최대 3,756,681
AMT_CREDIT_MAX_OVERDUE	비결측 중 79.51%	양수 최댓값 115,987,185
CNT_CREDIT_PROLONG	99.47%	양수 집단의 중앙값 1회

전체 데이터의 중앙값이나 IQR만 사용하면 이러한 소수 연체를 놓칠 수 있다. 그래서 다음 두 정보를 나누어 만들었다.

1. 양수 값이 존재하는지 나타내는 플래그
2. 양수 고객 안에서 상위 꼬리에 속하는지 나타내는 플래그

큰 값은 자동 삭제하지 않았다. 실제 다계약·고부채 고객일 수 있기 때문이다.

연체 관련 변수는 대부분 0이므로 “전형적인 고객”만 보면 연체 신호가 거의 보이지 않는다. 이번 분석은 먼저 **연체가 있었는지를** 나누고, 연체가 있었던 소수 고객 안에서 **얼마나 큰 값인지를** 다시 봤다. 이는 0이 많은 금융 행동 데이터를 다룰 때 중요한 방식이다.

4.5 값 범위와 시간 연속성

다음 항목은 정상 범위를 만족했다.

- `DAYS_CREDIT > 0` : 0건
- `MONTHS_BALANCE > 0` : 0건
- 음수 `CREDIT_DAY_OVERDUE` : 0건
- 음수 `CNT_CREDIT_PROLONG` : 0건
- 예상 밖 `STATUS` : 0건
- 계약별 중간 월 누락: 0건

`bureau_balance` 의 817,395개 계약은 최초 관측월부터 최근 관측월까지 월이 연속적으로 기록되어 있었다.

검토가 필요한 값도 있었다.

- `DAYS_CREDIT_UPDATE > 0` : 17건
- `AMT_CREDIT_SUM_DEBT < 0` : 8,418건
- `AMT_CREDIT_SUM_LIMIT < 0` : 351건

음수 부채와 음수 한도는 주로 신용카드에서 나타났다. 초과상환이나 잔액 기록 방식일 수 있으므로 삭제하지 않고 품질 플래그로 남겼다.

음수 값을 곧바로 “마이너스 부채이므로 매우 우량하다”라고 해석해서도 안 된다. 잔액 갱신시점이나 상품별 회계 처리 때문에 생긴 값일 수 있으므로, 일반 고객군과 분리해 확인하는 품질 집단으로 취급한다.

4.6 계약 내부의 논리 불일치

점검 항목	건수	해석
총부채가 총신용보다 큰 계약	29,642	비교 가능 계약의 2.03%
월별 과거 연체와 현재 연체 심도 차이가 2단계 이상	14,946	기준시점 차이 가능
연체금액이 총부채보다 큰 계약	9,198	대부분 음수 또는 0 부채
종료 계약인데 실제 종료일 없음	125	종료 계약의 0.012%
활성 계약인데 실제 종료일 있음	1,969	활성 계약의 0.312%
현재 연체일 0이지만 연체금액 양수	247	기록 기준 차이 가능
<code>c</code> 이후 최근 월에 다시 연체 상태 등장	43	상태 갱신 확인 필요

연체금액이 총부채보다 큰 9,198건 중 8,418건은 총부채가 음수였고 740건은 총부채가 0이었다. 총부채가 양수인데도 연체금액이 더 큰 사례는 40건뿐이었다.

이 값들은 삭제 기준이 아니라 기준시점 차이와 데이터 기록 방식을 보여주는 품질 특성으로 사용한다.

즉, 논리 불일치는 곧바로 잘못된 고객을 뜻하지 않는다. 월별 상태와 계약 요약값의 갱신일이 다르면 같은 계약도 서로 다른 시점을 설명할 수 있다. 후속 모델에서는 원값을 남기고 “불일치가 있었는가”라는 별도 플래그를 함께 사용한다.

5. 계약·고객 단위 파생변수

파생변수는 원본 여러 행을 고객의 금융상태를 설명하는 한두 개의 지표로 바꾼 값이다. 예를 들어 계약 4건 중 3건이 활성 상태라면 활성 계약 비율은 $3 \div 4 = 75\%$ 다. 계약별 신용금액 합계가 2,000이고 부채 합계가 1,000이라면 총부채/총신용 비율은 $1,000 \div 2,000 = 50\%$ 다.

이번 분석에서는 계약별 비율을 단순평균하지 않고 가능한 경우 먼저 금액이나 횟수를 합한 뒤 고객 단위 비율을 계산했다. 규모가 작은 계약과 큰 계약에 같은 가중치를 주는 오류를 줄이기 위해서다.

5.1 계약 단위 월별 이력

27,299,925개의 월별 행을 817,395개의 계약으로 집계했다.

- 계약당 관측기간: 평균 33.40개월, 중앙값 26개월, 최대 97개월
- 최근 3개월 관측 가능 계약: 633,172건(77.46%)
- 최근 6개월 관측 가능 계약: 648,799건(79.37%)
- 최근 12개월 관측 가능 계약: 677,572건(82.89%)
- 숫자 상태 1 ~ 5 가 한 번이라도 있는 계약: 103,264건(12.63%)
- 심각 연체 3 ~ 5 가 있는 계약: 8,368건(1.02%)
- 연체 후 0 또는 c 가 관측된 계약: 92,189건
- 최근 3개월의 최대 연체가 이전보다 악화된 계약: 비교 가능 계약 중 6,691건(4.12%)

최신 상태만 보면 숫자 연체 1 ~ 5 인 계약은 0.91%였다. 그러나 최신 상태가 정상이어도 과거에 연체했을 수 있으므로, 최신 상태와 전체기간 최대 연체를 따로 만들었다.

예를 들어 12개월 전에는 연체 상태 2 였지만 최근에는 0 인 계약은 “현재 연체 없음”과 “과거 최대 연체 2”를 동시에 가진다. 최신 상태 하나만 남기면 과거 상환문제를 놓치고, 최대 상태 하나만 남기면 최근 회복 여부를 놓친다.

5.2 고객 단위 외부 신용 특성

bureau 이력이 있는 305,811명을 고객당 1행으로 집계했다.

- 고객당 계약 수: 평균 5.61건, 중앙값 4건, 최대 116건
- 활성 계약 비율 평균: 41.02%
- 고객별 총신용 중앙값: 978,831
- 고객별 총부채 중앙값: 189,747
- 현재 연체 계약이 하나라도 있는 고객: 4,091명(1.34%)

- 총신용 분모가 없어 부채/신용 비율을 계산할 수 없는 고객: 1,276명(0.42%)
- 부채/신용 비율이 음수인 고객: 1,265명(0.41%)
- 부채/신용 비율이 1을 초과한 고객: 1,755명(0.57%)

총부채/총신용 비율은 계약별 비율을 평균내지 않고, 고객의 모든 계약을 합친 뒤 **총부채 ÷ 총신용** 으로 계산했다.

이 비율은 대략적으로 “외부 신용금액에 비해 현재 부채가 얼마나 남아 있는가”를 보여준다.

- 0: 기록상 현재 부채가 없음
- 0.25: 총신용의 약 25%에 해당하는 부채가 남아 있음
- 1.00: 총부채와 총신용이 같은 크기
- 1 초과: 부채가 신용금액보다 크게 기록된 특이 집단

다만 상품별 정의와 갱신시점이 다를 수 있으므로 일반적인 회계 비율처럼 정확히 “상환 진척률”로 단정하지 않는다.

5.3 월별 이력과 고객 특성의 결합

고객 구분	고객 수	bureau 고객 내 비율
모든 계약에 월별 이력 없음	171,269	56.00%
모든 계약에 월별 이력 있음	134,108	43.85%
일부 계약에만 월별 이력 있음	434	0.14%

- 월별 이력이 하나라도 있는 고객은 134,542명(44.00%)이었다.
- **C·X**를 제외한 숫자 상태가 있는 고객은 130,773명(42.76%)이었다.
- 계산 가능한 고객의 가중 연체월 비율은 평균 3.92%, 중앙값 0이었다.
- 최근 12개월 연체가 있는 활성 계약을 보유한 고객은 17,913명(5.86%)이었다.
- 현재 연체 심도가 과거 월별 최대 상태보다 2단계 이상 큰 고객은 9,698명(3.17%)이었다.

고객 연체월 비율은 계약별 비율의 단순평균이 아니라, 고객의 전체 연체월 수를 전체 유효 관측월 수로 나눈 가중 비율로 계산했다.

예를 들어 계약 A가 2개월 중 1개월 연체, 계약 B가 18개월 중 0개월 연체라면 계약별 비율의 단순평균은 $(50\% + 0\%) \div 2 = 25\%$ 다. 그러나 실제 전체 관측월 기준 연체 비율은 $1 \div 20 = 5\%$ 다. 이번 분석은 후자의 가중 방식을 사용한다.

5.4 파생변수 검증

최종 산출물은 다음과 같다.

산출물	크기
월별 계약 특성	817,395행 × 30열
bureau 와 월별 특성의 계약 결합표	1,716,428행 × 54열
고객 단위 특성	305,811행 × 59열

기준 키의 유일성, 최근 3·6·12개월 연체 건수와 관측월 수 관계, 비율 범위, 상품유형 비율 합계 등 16개 검증을 모두 통과했다.

6. 기초 분포와 시각화


이 절의 그래프는 먼저 “데이터가 어떻게 생겼는가”를 확인하는 그림이다. 6.1~6.4의 분포만으로 상환곤란 위험을 판단하지 않는다. 실제 **TARGET** 과의 관계는 8절에서 별도로 비교한다.

그래프를 읽을 때는 다음을 구분해야 한다.

- 고객 수가 많은 구간: 데이터에서 흔한 특성
- 값이 큰 구간: 드물지만 규모가 큰 특성
- 상환곤란률이 높은 구간: train 고객 중 **TARGET=1** 비율이 높은 특성

흔한 특성과 위험한 특성은 같은 말이 아니다.

6.1 계약 수와 관측기간




- 고객별 계약 수 중앙값은 4건, 95백분위는 14건, 99백분위는 21건이었다.
- 21건을 초과한 고객은 2,397명(0.78%)이었다.
- 계약별 관측기간 중앙값은 26개월, 95백분위는 90개월, 최대는 97개월이었다.

계약 수와 관측기간 모두 오른쪽 꼬리가 길지만, 긴 이력이나 많은 계약을 자동으로 이상치 처리하지 않았다.

“95백분위가 계약 14건”이라는 말은 고객의 약 95%가 14건 이하의 계약을 보유하고, 나머지 약 5%가 그보다 많은 계약을 보유한다는 뜻이다. 21건 초과 고객은 전체의 0.78%로 드물지만 실제 다계약 고객일 수 있으므로 별도 플레그로 남긴다.


6.2 계약 상태와 상품 구성



- 전체 계약의 62.88%는 종료, 36.74%는 활성 상태였다.
- Consumer credit와 Credit card가 전체 계약의 96.35%를 차지했다.
- 월별 이력이 있는 계약의 최신 상태는 **C** 55.00%, **X** 24.84%, **0** 19.25%였다.

최신 월 상태에서 **C**와 **X**가 큰 비중을 차지하므로, 최신 월 한 개만 보고 고객의 상환이력을 판단하기 어렵다. 종료된 계약은 과거 연체가 있었을 수 있고, **X**는 정상 여부를 판단할 수 없기 때문이다.

6.3 총신용과 총부채




- 산점도에는 총신용이 양수이고 총부채가 0 이상인 295,027명을 사용했다.
- 유효한 총부채가 있는 고객 중 총부채 0인 고객은 80,654명(27.12%)이었다.
- 대부분은 **총부채 = 총신용** 기준선 아래에 있었지만, 비율이 1을 초과한 고객도 존재했다.

이 그림은 두 금액의 분포 관계만 보여준다. 이 자체로 상환곤란의 원인이라고 해석하지 않는다.

대각선 아래에 있는 고객은 기록상 총부채가 총신용보다 작다. 대각선 위의 소수 고객은 총부채/총신용 비율이 1을 초과한다. 이들은 고부채 고객일 수도 있지만, 갹신시점 차이나 원천 기록 방식도 섞일 수 있어 별도 품질 플래그와 함께 해석한다.

6.4 월별 이력과 최근 연체



숫자 월 상태가 있는 고객을 기준으로 다음과 같이 구분했다.

구분	고객 수
관측기간 연체 없음	82,251
과거 연체만 있음	25,084
최근 12개월 연체 있음	23,438
숫자 상태 없음	175,038

최근 구간에 실제 관측이 있는 고객만 분모로 계산한 연체 고객 비율은 최근 3개월 8.44%, 6개월 12.54%, 12개월 17.72%였다. 이 구간들은 서로 포함되므로 기간이 길어질수록 비율이 커지는 것은 자연스럽다.

예를 들어 최근 3개월에 연체한 고객은 최근 6개월과 12개월 집단에도 포함된다. 따라서 8.44%, 12.54%, 17.72%를 서로 독립된 세 집단의 위험률처럼 비교하면 안 된다. 이 값은 관측 창을 넓힐수록 연체 경험을 포착하는 고객이 얼마나 늘어나는지를 보여준다.

7. TARGET 분석 모집단과 train/test 사용 경계

7.1 데이터별 역할

이번 보고서의 상환곤란 EDA는 `application_train` 만 사용한다.

데이터	고객 수	TARGET	이번 분석에서의 사용
<code>application_train</code>	307,511	0 또는 1	모든 TARGET 비율·비교 분석에 사용
<code>application_test</code>	48,744	없음	TARGET 분석에 사용하지 않음

`application_test` 에는 정답인 TARGET 이 없으므로 상환곤란률을 계산할 수 없다. test 고객에게 TARGET=0 이나 전체 평균을 임의로 넣지도 않았다. 8절의 모든 고객 수, 상환곤란 고객 수와 상환곤란률은 `application_train` 307,511명만으로 계산했다.

7.2 application_train의 외부신용 이력 구성

TARGET 분석 대상인 train 고객을 외부신용 이력 보유 상태에 따라 나누면 다음과 같다.

외부신용 이력 구분	train 고객 수	train 내 비율	TARGET=1 고객 수	상환곤란률
외부신용 계약 없음	44,020	14.31%	4,457	10.12%
계약은 있으나 월별 이력 없음	171,260	55.69%	12,858	7.51%
월별 이력 있음	92,231	29.99%	7,510	8.14%
합계	307,511	100.00%	24,825	8.07%

개별 비율은 소수점 둘째 자리에서 반올림했으므로 표시값의 합이 99.99%로 보일 수 있지만, 실제 고객 수 기준 합계는 307,511명이다.

이 표는 train 고객만으로 만든 TARGET EDA의 시작점이다. 외부신용 계약이 없는 train 고객의 상환곤란률은 10.12%로 전체 평균 8.07%보다 높았다. 다만 이를 “외부신용 이력이 없어서 위험하다”는 인과관계로 해석할 수는 없다. 다른 고객 특성과 정보 부족이 함께 반영됐을 수 있다.

train 고객의 70.01%는 “외부신용 계약 없음” 또는 “계약은 있지만 월별 이력 없음” 집단이다. 따라서 월별 연체정보가 충분한 고객에게서 발견한 규칙을 모든 train 고객에게 그대로 적용하기 어렵다. 후속 분석에서는 이력 보유 여부와 관측월 수를 함께 사용해야 한다.

또한 “계약 없음”은 정말 외부 신용을 사용하지 않은 고객일 수도 있고, 해당 데이터 소스에서 계약이 연결되지 않은 고객일 수도 있다. 따라서 그 자체를 우량 또는 위험으로 단정하지 않는다.

8. 외부 신용이력과 상환곤란의 관계 — application_train만 사용

application_train 전체 고객의 상환곤란률은 8.07%였다.

이 절의 표는 고객을 한 가지 특성으로 나눈 **단변량 비교**다. 즉, 활성 계약 비율 표는 소득·나이·신청금액 등이 같은 고객끼리 비교한 결과가 아니다. 따라서 여기서는 후속 분석에 넣을 후보 변수를 찾고, 최종 판단은 여러 특성을 동시에 고려하는 분석에서 다시 확인한다.

각 표의 구간은 서로 겹치지 않으며, 고객 수를 모두 더하면 application_train 307,511명이 된다. “외부신용 계약 없음”, “숫자 월 상태 없음”, “분모 무효/결측”을 표에서 빼지 않은 이유도 정보 부재 집단까지 train 모집단 안에서 함께 보기 위해서다.

8.1 고객당 계약 수

계약 수 구간	train 고객 수	상환곤란 고객 수	상환곤란률
외부신용 계약 없음	44,020	4,457	10.12%
1~2건	71,707	5,882	8.20%
3~4건	61,898	4,570	7.38%
5~7건	63,210	4,626	7.32%

계약 수 구간	train 고객 수	상환곤란 고객 수	상환곤란률
8~14건	55,033	4,201	7.63%
15건 이상	11,643	1,089	9.35%

계약 수는 많아질수록 상환곤란률이 일정하게 증가하지 않았다. 3~7건에서 낮아졌다가 15건 이상에서 다시 높아지는 U자형에 가까운 관계가 나타났다.

계약 15건 이상 집단은 5~7건 집단보다 상환곤란률이 2.03%p 높다. 그러나 외부신용 계약이 없는 집단도 10.12%로 높다. 따라서 “계약을 줄일수록 무조건 안전하다”는 결론은 성립하지 않는다. 계약 수는 신용활동의 규모를 나타내지만, 현재 남은 부채와 최근 연체를 함께 봐야 의미가 생긴다.

8.2 활성 계약 비율

활성 계약 비율	train 고객 수	상환곤란 고객 수	상환곤란률
외부신용 계약 없음	44,020	4,457	10.12%
0	46,341	2,621	5.66%
0 초과~0.25	45,775	2,442	5.33%
0.25 초과~0.50	98,292	7,339	7.47%
0.50 초과~0.75	35,742	3,702	10.36%
0.75 초과~1.00	37,341	4,264	11.42%

현재 활성 상태인 계약의 비중이 높을수록 상환곤란률도 높아지는 뚜렷한 관측 패턴이 나타났다.

활성 계약 비율이 0 초과~25%인 집단과 75% 초과 집단의 차이는 6.09%p다. 고객 100명으로 단순 환산하면 약 5명 대 11명의 차이이다. 이는 아직 상환 중인 계약이 차지하는 비중이 현재 금융부담을 설명하는 유용한 후보라는 뜻이다.

다만 활성 계약은 정상적으로 이용 중인 계약일 수도 있다. 활성 계약이 많다는 이유만으로 연체 고객으로 분류해서는 안 되며, 부채 규모·연체 최근성·소득 대비 상환부담을 함께 봐야 한다.

8.3 총부채/총신용 비율

총부채/총신용 비율	train 고객 수	상환곤란 고객 수	상환곤란률
외부신용 계약 없음	44,020	4,457	10.12%
분모 무효/결측	8,337	575	6.90%
음수	1,265	49	3.87%
0	68,776	3,824	5.56%
0 초과~0.25	64,234	4,040	6.29%
0.25 초과~0.50	58,679	4,656	7.93%
0.50 초과~0.75	38,680	4,053	10.48%
0.75 초과~1.00	21,935	2,876	13.11%


총부채/총신용 비율	train 고객 수	상환곤란 고객 수	상환곤란률
1 초과	1,585	295	18.61%

부채 비율은 이번 분석에서 상환곤란률과 가장 뚜렷한 단계적 관계를 보인 변수다. 다만 1 초과 집단은 1,585명으로 상대적으로 작으므로 후속 분석에서 표본 수와 신뢰구간을 함께 확인해야 한다.

음수 비율 집단의 상환곤란률은 3.87%였지만, 이를 우량 고객 특성으로 해석하지 않는다. 음수 부채와 갹신시점 차이가 섞인 데이터 품질 집단이기 때문이다.

비율이 0인 집단과 0.75 초과~1.00인 집단의 차이는 7.55%p이고, 1 초과 집단과의 차이는 13.05%p다. 비율이 커질수록 상환곤란률이 단계적으로 증가한다는 점에서 우선순위가 높은 변수다.

그러나 1 초과 집단은 `application_train` 전체 고객의 약 0.52%에 불과하다. 18.61%라는 큰 숫자만 보고 전체 정책의 기준으로 삼기보다, 원천 기록을 재점검하고 다른 특성을 통제된 뒤 별도 고위험 후보군으로 검토해야 한다.



8.4 과거 최대 연체 상태

과거 최대 월 상태	train 고객 수	상환곤란 고객 수	상환곤란률
외부신용 계약 없음	44,020	4,457	10.12%
숫자 월 상태 없음	173,635	13,042	7.51%
최대 0	58,804	4,234	7.20%
최대 1	24,686	2,483	10.06%
최대 2	2,961	259	8.75%
최대 3~5	3,405	350	10.28%

연체 단계가 높아질수록 항상 상환곤란률이 증가하는 완전한 단조 관계는 아니었다. 특히 최대 2, 최대 3~5 집단은 표본이 작으므로 점추정치만 비교하면 안 된다.

최대 상태 1과 3~5 집단은 최대 0 집단보다 각각 2.86%p, 3.08%p 높았다. 반면 최대 2는 8.75%로 중간에 내려간다. 이는 연체 단계 하나만으로 순위를 고정하기 어렵고, 최근성·반복 횟수·고객 수를 함께 봐야 한다는 의미다.

특히 숫자 월 상태 없음은 연체가 없었다는 뜻이 아니다. 월별 이력이 없거나 C·X만 있어 숫자 상태를 판단할 수 없는 고객이다.


8.5 연체의 최근성

연체 시점 구분	train 고객 수	상환곤란 고객 수	상환곤란률
외부신용 계약 없음	44,020	4,457	10.12%
숫자 월 상태 없음	173,635	13,042	7.51%
관측기간 연체 없음	58,804	4,234	7.20%
과거에만 연체	15,707	1,283	8.17%
최근 12개월 연체	15,345	1,809	11.79%

최근 연체 집단은 과거 연체 집단보다 상환곤란률이 높았다. 따라서 전체기간 최대 연체 상태뿐 아니라 **최근 12개월 연체 여부와 횟수**를 별도로 유지해야 한다.

최근 12개월 연체 집단은 관측기간 연체 없음 집단보다 4.59%p 높고, 과거에만 연체한 집단보다 3.62%p 높다. 같은 “연체 경험 고객” 안에서도 최근 연체가 더 강한 신호일 수 있음을 보여준다.

이 결과를 실무적으로 번역하면, 오래전 한 번의 연체와 최근 반복되는 연체를 같은 위험등급으로 처리하면 안 된다는 뜻이다. 다만 최근 12개월 동안 실제 월별 관측이 있었던 고객에게만 이 변수를 신뢰할 수 있으므로 이력 커버리지도 함께 사용한다.



9. 후속 분석에서 사용할 변수

변수	쉬운 의미	사용하는 이유
BUR_ACTIVE_RATIO	전체 외부 계약 중 현재 활성 계약 비율	높을수록 상환곤란률이 높았음
BUR_DEBT_CREDIT_RATIO	총신용 대비 현재 총부채 비율	상환곤란률과 가장 뚜렷한 단계적 관계
최근 12개월 연체 여부·횟수	최근에 연체가 있었는지	과거 연체보다 최근 연체의 관계가 강했음
전체기간 최대 연체 상태	관측된 가장 심한 연체 단계	과거 신용 문제의 심도 표현
외부 신용계약 수	다른 금융기관 계약 개수	비선형 관계 확인

변수	쉬운 의미	사용하는 이유
월별 이력 커버리지	전체 계약 중 월별 이력이 있는 비율	정보 부족과 정상 상태 구분
외부신용 이력 없음 플래그	bureau 계약 자체가 없는지	이력 부재 집단을 별도로 표현
음수·1 초과·불일치 플래그	금액 또는 상태 기록의 특이점	원값 삭제 없이 품질 차이 보존

이 변수들은 각각 다른 질문에 답한다.

판단 영역	대표 변수	답하려는 질문
현재 부담	활성 계약 비율, 총부채/총신용 비율	지금도 진행 중인 외부 채무 부담이 큰가?
과거 행동	최대 연체 상태, 최근 12개월 연체 여부·횟수	과거에 얼마나 심하게, 얼마나 최근에 상황이 늦었는가?
신용활동 규모	외부 계약 수, 상품별 계약 수	외부 금융거래가 얼마나 많고 복잡한가?
정보 신뢰도	월별 이력 보유 여부·관측월 수	위 판단을 뒷받침할 정보가 충분한가?
데이터 품질	음수·1 초과·현재·과거 불일치 플래그	일반 고객과 같은 방식으로 해석해도 되는가?

후속 분석에서는 한 변수만으로 고객을 판단하지 않고 다음처럼 조합해서 본다.

- **현재 부담이 낮고 최근 연체가 없는 고객:** 상환여력이 충분한지 Application의 소득·연상환액과 함께 확인한다.
- **현재 부담이 높고 최근 연체도 있는 고객:** 조건 조정만으로 위험이 충분히 낮아지는지 보수적으로 검토한다.
- **외부 이력이 부족한 고객:** 위험 0으로 두지 않고, Application 정보나 다른 내부 이력을 더 요구하는 별도 집단으로 본다.
- **음수 부채나 비율 1 초과 고객:** 우량·고위험으로 즉시 분류하지 않고 원천값과 상품유형을 재확인한다.

위 내용은 아직 검증된 승인정책이 아니라 **2차 EDA와 모델 검증에서 확인할 분석 가설**이다.

후속 2차 EDA에서는 Application의 신청금액, 소득, 연상환액으로 상환부담 변수를 만들고 위 변수와 함께 분석해야 한다.

예를 들면 다음 질문을 확인할 수 있다.

- 소득 대비 상환부담이 같아도 기존 부채 비율이 높은 고객의 위험이 더 높은가?
- 신청금액을 줄였을 때 최근 연체 고객과 비연체 고객의 위험 변화가 다른가?
- 활성 계약이 많지만 최근 연체가 없는 고객은 조건 조정 가능성이 있는가?
- 이력이 없는 고객은 별도 기준이나 추가 정보 확인이 필요한가?

진행 순서는 다음이 적절하다.

1. 소득 대비 연상환액, 신청금액 대비 소득 등 Application 상환부담 변수를 만든다.
2. 외부 부채 비율과 최근 연체를 함께 넣어 각 변수의 관계가 다른 특성을 통제된 뒤에도 유지되는지 확인한다.
3. 계약 수와 부채 비율의 비선형 관계를 구간화·스플라인·트리 기반 방법 등으로 비교한다.
4. 이력 없음 집단과 이력 있음 집단에서 같은 규칙이 작동하는지 분리 검증한다.
5. 교차검증과 신뢰구간을 사용해 작은 집단의 우연한 비율 변동을 확인한다.
6. 그다음에야 신청금액 또는 상환조건 조정 시나리오를 계산한다.

10. 해석할 때 반드시 지켜야 할 한계

먼저 이번 분석으로 말할 수 있는 것과 아직 말할 수 없는 것을 분리하면 다음과 같다.

말할 수 있는 것	아직 말할 수 없는 것
부채 비율이 높은 집단에서 상환곤란률이 더 높게 관측됐다.	부채 비율만 낮추면 같은 폭으로 상환곤란률이 감소한다.
최근 연체 집단이 과거 연체 집단보다 높은 비율을 보였다.	최근 연체가 상환곤란의 유일한 원인이다.
외부신용 이력 없음 집단과 이력 보유 집단의 비율이 달랐다.	외부신용 이력을 만들면 고객 위험이 낮아진다.
계약 수와 상환곤란률의 관계가 비선형이었다.	특정 계약 수가 모든 고객에게 안전 또는 위험 기준이다.
후속 분석에 사용할 후보 변수를 정할 수 있다.	이 결과만으로 승인·거절 또는 금리·한도를 결정할 수 있다.

1. **TARGET** 은 승인·거절 라벨이 아니다.

대출 실행 후 상환곤란 여부이므로 실제 금융회사의 승인정책을 재현할 수 없다.

2. 관측 관계는 인과관계가 아니다.

부채 비율이 높은 고객의 상환곤란률이 높았다고 해서 대출금액을 줄이면 같은 폭으로 위험이 낮아진다고 바로 결론내릴 수 없다.

3. **application_test** 는 **TARGET** 분석에 사용하지 않는다.

test에는 **TARGET** 이 없으므로 상환곤란률의 분자·분모, 8절의 구간 비교와 후속 모델 학습에 포함하지 않는다.

4. 이력 없음, 값 0, 상태 미상은 서로 다르다.

이를 하나로 합치면 중요한 정보 차이가 사라진다.

5. 극단값과 음수 값을 자동 삭제하지 않는다.

실제 고부채 고객, 초과상환, 갹신시점 차이일 수 있으므로 원값과 품질 플래그를 함께 사용한다.

6. 작은 집단의 비율은 불확실성이 크다.

최대 연체 2~3~5, 부채 비율 1 초과 집단 등은 표본 수와 신뢰구간을 함께 봐야 한다.

7. 금액 변수의 통화·경제적 의미를 과도하게 확대하지 않는다.

원천 데이터의 익명화된 금액을 실제 원화 금액이나 현재 금융기관의 상품 정의와 동일하다고 가정하지 않는다.

8. 현재 문서는 단변량 EDA 결과다.

소득, 신청금액, 연령, 고용상태 등 다른 특성을 동시에 고려하지 않았으므로 집단 간 구성 차이가 결과에 섞여 있을 수 있다.

9. 관측기간이 고객마다 다르다.

최근 3~6~12개월 지표는 해당 기간의 실제 관측월 수와 함께 사용해야 하며, 관측이 없는 고객을 비연체로 채우지 않는다.

향후 위험도 모델이 필요하더라도 종료된 Kaggle 대회의 test 제출을 목적으로 사용하지 않는다. **TARGET** 이 있는 고객 안에서 교차검증하고, 모델은 그레이존과 조건 조정 시나리오를 설명하기 위한 도구로 사용한다.

11. 최종 결론

이번 1차 EDA를 통해 외부 신용이력은 다음 세 가지 측면에서 구분해야 한다는 점을 확인했다.

1. **현재 부담**: 활성 계약 비율과 총부채/총신용 비율
2. **과거 행동**: 최대 연체 심도와 최근 연체 여부
3. **정보의 양**: 외부 계약 및 월별 이력 보유 여부

특히 총부채/총신용 비율과 최근 12개월 연체 여부는 상환곤란률 차이가 뚜렷했다. 반면 계약 수와 최대 연체 단계는 단순한 직선 관계가 아니므로 구간화나 비선형 분석이 필요하다.

따라서 2차 EDA에서는 Application의 상환부담 변수와 외부 신용이력을 결합해, 어떤 고객에게 조건 조정이 가능하고 어떤 고객에게는 효과가 제한적인지를 확인하는 것이 적절하다.

부록 A. application_test 참고 점검의 범위

`application_test` 48,744명은 TARGET EDA에 사용하지 않았다. 다음 항목만 별도 참고 점검했다.

- train과 test를 합쳤을 때 `SK_ID_CURR` 중복이 없는지
- 생성한 bureau 고객 특성이 Application 고객 키와 정상적으로 연결되는지
- 라벨이 없는 test 고객에게도 외부신용 이력이 어느 정도 존재하는지

참고 점검용 구분	고객 수
<code>application_train</code>	307,511
<code>application_test</code>	48,744
키 점검용 단순 합계	356,255
중복 <code>SK_ID_CURR</code>	0

이 356,255명은 **TARGET 분석 모집단이 아니다**. train+test 통합 고객 수와 커버리지 통계는 데이터 연결 상태를 확인하기 위한 참고값일 뿐, 8절의 상환곤란률이나 변수별 위험 비교에는 사용하지 않았다.

부록 B. 재현 및 근거 파일

- 실행 노트북: 07.27 1차 EDA.ipynb
- 시각화 및 요약 CSV: `figures`
- 재사용 파생변수: `artifacts/jsw_bureau_eda/`
- `bb_contract_features.pkl`
- `customer_feature_table.pkl`

모든 그래프의 수치 근거는 `figures` 폴더의 CSV로 함께 저장되어 있다.